📚 Book Market: Literatur trifft Data Science

Alles rund um Bücher. Interaktiv. Intelligent. Buchmarkt mit Datenblick.

📊 Wirtschaftsanalyse

Analyse wirtschaftlicher Einflussfaktoren auf den Buchumsatz: Genre, Bewertung, Verlag und mehr.

- Bereinigung & Auswertung von Daten der letzten 20 Jahre
- Visualisierung von Zusammenhängen
- Regressionsmodell zur Umsatzprognose
- Handlungsempfehlungen für Verlage und Autor*innen

🤖 Buchempfehlungssystem

Personalisierte Buchempfehlungen auf Basis semantischer Ähnlichkeit und benutzerdefinierter Filter.

- Inhaltsbasierte Empfehlungen zu einem gewählten Buch
- Filterung nach Genre, Autor, Erscheinungsjahr und Bewertung
- Nutzung von SentenceTransformers & Cosine Similarity

🎥 🎞️ ⭐ Verfilmungsprognose

Kann man vorhersagen, ob ein frisch erschienenes Buch eines Tages erfolgreich wird – und schließlich auf der Leinwand landet?

- Analyse von Genre, Sprache, Bewertung, Verkäufen & Verfilmungsstatus
- Visuelle Darstellung relevanter Zusammenhänge
- Entwicklung eines Prognosemodells (logistische Regression)
- Bewertung der Vorhersagekraft mittels Accuracy, Precision & AUC

📎 Credits

Dieses Projekt wurde im Rahmen des Data Science Institute entwickelt.

Verwendete Modelle und Methoden:

Explorative Datenanalyse (Pandas, Seaborn, Matplotlib)

Lineare Regressionsmodelle zur Untersuchung von Einflussfaktoren auf den Bruttoumsatz

Korrelationsanalysen (Pearson)

Logistische Regression zur Verfilmungsprognose

Modellbewertung mittels Accuracy, Precision, Recall, AUC

Semantische Textanalyse mit SentenceTransformers

TF-IDF-Vektorisierung & Cosine Similarity

Text-Preprocessing inkl. Tokenisierung, Stopword-Filterung (NLTK & scikit-learn)

WordClouds zur Visualisierung

Technologien & Bibliotheken:
Streamlit · Pandas · NumPy · scikit-learn · Matplotlib · Seaborn · SentenceTransformers · NLTK · PyTorch · requests · ast

Projektmanagement mit **SCRUM**

Zusammenarbeit & Versionskontrolle mit **GitHub**

Datenquellen: Kaggle, Goodreads, Open Library, Google Books API

🎬 Prognose von Buchverfilmungen für Neuerscheinungen 2021–2025

📘 Projekt-Navigation

📚 Buchmarkt analysieren – Empfehlungen & Filmchance inklusive.

Wähle eine Funktion:

- ○ Startseite
- ○ Wirtschaftsanalyse
- ○ Empfehlungssystem
- ● Verfilmungsprognose

🔧 Threshold für Vorhersage ⓘ

0.50

0.00 — 1.00

👤 Wähle einen Autor

Stephen King

📚 Wähle ein Buch

Holly

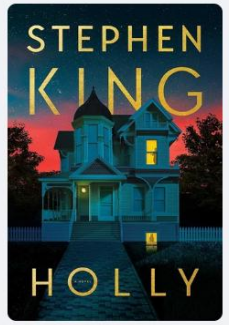

Buchcover

📖 Details zum ausgewählten Buch: 🔗

	Publishing_Year	Book_Name	Author	Language_Code	Author_Rating	Average_Rating	Rating_Count	Gross_Sales_EUR	Publisher	Genre	ISBN
12	2023	Holly	Stephen King	en	Famous	4.1	168800	7000000000	Scribner	Horror	9781668016138

📊 **Wahrscheinlichkeit für Verfilmung: 51%**

🎬 **Erfolg!** Das Buch *Holly* von *Stephen King* wird voraussichtlich verfilmt! 🍿
(Schwellenwert: 50%)

📊 Rückblick: Wie gut sagt das Modell echte Verfilmungen voraus?

📅 Zur Machine Learning-Daten →

🤖 Logistisches Regressionsmodell mit geänderten Threshold 🎚 0.50

Der Threshold-Schwellenwert bestimmt, ""ab welcher Wahrscheinlichkeit ein Buch als „verfilmt" gilt"".
Ein niedrigerer Wert erkennt mehr mögliche Verfilmungen (höherer Recall),
ein höherer Wert reduziert Fehlalarme (höhere Precision).
(Dynamisch anpassbar über den Schieberegler seitlich)

📊 Modell-Metriken im Überblick

	Metrik	Wert	Erklärung
0	Recall	0.32	Erkannt: Wie viele echte Verfilmungen korrekt erkannt wurden. **Je näher an 1.00, desto besser.**
1	Precision	0.70	Treffer: Wie viele Vorhersagen für Verfilmung auch wirklich stimmen. **Hoher Wert = wenig Fehlalarme.**
2	F1-Score	0.44	Balance zwischen Precision & Recall. **Ideal bei unausgeglichenen Klassen.**
3	Accuracy	0.66	Genauigkeit/Gesamttrefferquote – Anteil der korrekten Vorhersagen an allen Fällen. **Kann bei Ungleichverteilung trügen.**
4	ROC-AUC	0.71	Trennschärfe unabhängig vom Schwellenwert. **Über 0.80 = sehr gutes Modell.**

🧮 Verfilmungen: Was das Modell richtig oder falsch erkennt

Confusionsmatrix zeigt, wie viele Bücher das Modell richtig oder falsch als verfilmt bzw. nicht verfilmt erkannt hat.
So sieht man auf einen Blick, wo das Modell gut ist und wo es Fehler macht.

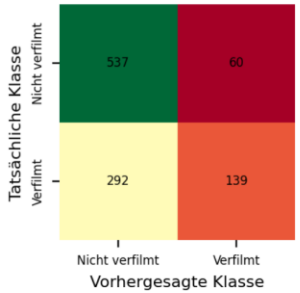

📉 Threshold-Sensitivität: Trefferquote bei unterschiedlichen Grenzen

Zeigt, wie gut das Modell Verfilmungen erkennt, wenn wir die Entscheidungsschwelle verändern.
Eine Kurve, die oben rechts liegt, bedeutet bessere Vorhersagen.

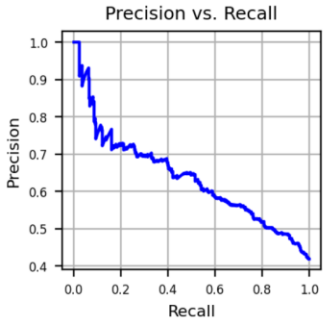

Anzahl Bücher pro Jahr

Jahr auswählen

1925 2024

1925 2024

Welche Grafik möchtest du sehen?

- Anzahl Bücher pro Jahr
- Bewertung vs. Umsatz (Scatterplot)
- Verfilmte Bücher pro Jahr
- Top Genres
- Bewertungsverteilung
- Verfilmungsanteil
- Top Autor:innen
- Ø Bewertung nach Autor:innen-Rating
- Bewertungen pro Jahr
- Umsatz vs. Jahr (Farbskala: Bewertung)
- Bewertungen vs. Jahr (Farbskala: Autor-Rating)

BUCHDATEN

Bereinigte Daten für ML Model, Verlauf über die Jahre (1925–2024)

	Publishing_Year	Book_Name	Author	Langu
0	1975	Beowulf	Unknown, Seamus Heaney	en
1	1987	Batman: Year One	Frank Miller, David Mazzucch	en
2	2015	Go Set a Watchman	Harper Lee	en
3	2008	When You Are Engulfed in Flames	David Sedaris	en
4	2011	Daughter of Smoke & Bone	Laini Taylor	en
5	2015	Red Queen	Victoria Aveyard	en
6	2011	The Power of Habit	Charles Duhigg	en
7	1994	Midnight in the Garden of Good and Evil	John Berendt	en
8	2012	Hopeless	Colleen Hoover	en
9	2004	The Truth About Forever	Sarah Dessen	en

Numerische Basisstatistiken:

	Publishing_Year	Average_Rating	Rating_Count	Gross_Sales_EUR	Adapted_to_Film
count	1028	1028	1028	1028	1028
mean	1997.8132	4.0177	190934.7928	7751892857.4299	0.4193
std	19.0682	0.2528	722351.3114	90856758766.0418	0.4937
min	1925	2.97	540	104.94	0
25%	1993	3.86	70875	667.85	0
50%	2004	4.03	90912.5	30171	0
75%	2011	4.18	119736	971885	1
max	2024	4.77	11024224	1900000000000	1

Visualisierung

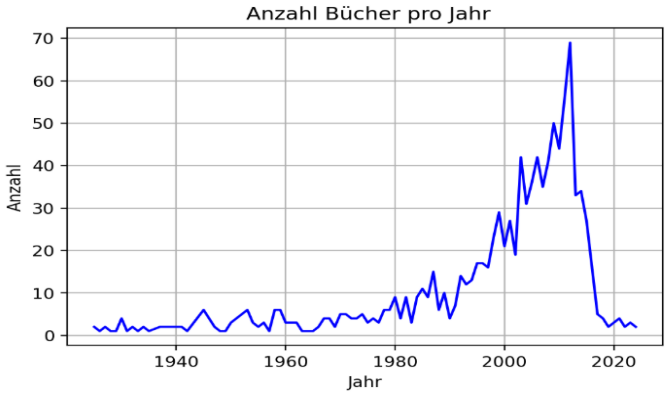

Bewertung vs. Umsatz

Jahr auswählen

1925 2024

1925 2024

Welche Grafik möchtest du sehen?

- Anzahl Bücher pro Jahr
- Bewertung vs. Umsatz (Scatterplot)
- Verfilmte Bücher pro Jahr
- Top Genres
- Bewertungsverteilung
- Verfilmungsanteil
- Top Autor:innen
- Ø Bewertung nach Autor:innen-Rating
- Bewertungen pro Jahr
- Umsatz vs. Jahr (Farbskala: Bewertung)
- Bewertungen vs. Jahr (Farbskala: Autor-Rating)

BUCHDATEN

Bereinigte Daten für ML Model, Verlauf über die Jahre (1925–2024)

	Publishing_Year	Book_Name	Author	Langu
0	1975	Beowulf	Unknown, Seamus Heaney	en
1	1987	Batman: Year One	Frank Miller, David Mazzucch	en
2	2015	Go Set a Watchman	Harper Lee	en
3	2008	When You Are Engulfed in Flames	David Sedaris	en
4	2011	Daughter of Smoke & Bone	Laini Taylor	en
5	2015	Red Queen	Victoria Aveyard	en
6	2011	The Power of Habit	Charles Duhigg	en
7	1994	Midnight in the Garden of Good and Evil	John Berendt	en
8	2012	Hopeless	Colleen Hoover	en
9	2004	The Truth About Forever	Sarah Dessen	en

Verfilmungsprognose

Numerische Basisstatistiken:

	Publishing_Year	Average_Rating	Rating_Count	Gross_Sales_EUR	Adapted_to_Film
count	1028	1028	1028	1028	1028
mean	1997.8132	4.0177	190934.7928	7751892857.4299	0.4193
std	19.0682	0.2528	722351.3114	90856758766.0418	0.4937
min	1925	2.97	540	104.94	0
25%	1993	3.86	70875	667.85	0
50%	2004	4.03	90912.5	30171	0
75%	2011	4.18	119736	971885	1
max	2024	4.77	11024224	1900000000000	1

Visualisierung

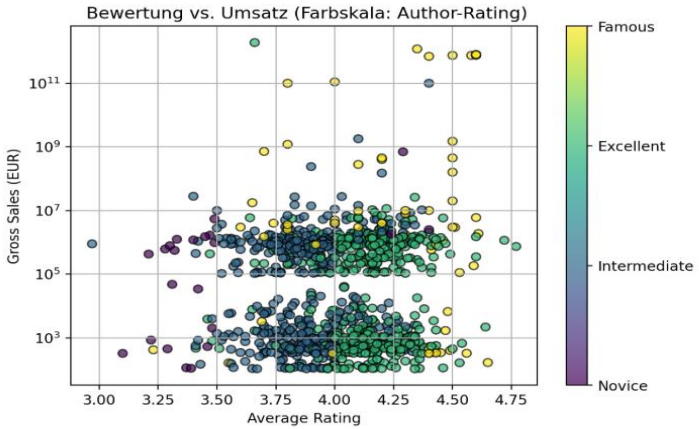

Verfilmte Bücher pro Jahr

Jahr auswählen

1925 2024

1925 2024

Welche Grafik möchtest du sehen?

- Anzahl Bücher pro Jahr
- Bewertung vs. Umsatz (Scatterplot)
- Verfilmte Bücher pro Jahr
- Top Genres
- Bewertungsverteilung
- Verfilmungsanteil
- Top Autor:innen
- Ø Bewertung nach Autor:innen-Rating
- Bewertungen pro Jahr
- Umsatz vs. Jahr (Farbskala: Bewertung)
- Bewertungen vs. Jahr (Farbskala: Autor-Rating)

BUCHDATEN

Bereinigte Daten für ML Model, Verlauf über die Jahre (1925–2024)

	Publishing_Year	Book_Name	Author	Lang
0	1975	Beowulf	Unknown, Seamus Heaney	en
1	1987	Batman: Year One	Frank Miller, David Mazzucch	en
2	2015	Go Set a Watchman	Harper Lee	en
3	2008	When You Are Engulfed in Flames	David Sedaris	en
4	2011	Daughter of Smoke & Bone	Laini Taylor	en
5	2015	Red Queen	Victoria Aveyard	en
6	2011	The Power of Habit	Charles Duhigg	en
7	1994	Midnight in the Garden of Good and Evil	John Berendt	en
8	2012	Hopeless	Colleen Hoover	en
9	2004	The Truth About Forever	Sarah Dessen	en

Numerische Basisstatistiken:

	Publishing_Year	Average_Rating	Rating_Count	Gross_Sales_EUR	Adapted_to_Film
count	1028	1028	1028	1028	1028
mean	1997.8132	4.0177	190934.7928	7751892857.4299	0.4193
std	19.0682	0.2528	722351.3114	90856758766.0418	0.4937
min	1925	2.97	540	104.94	0
25%	1993	3.86	70875	667.85	0
50%	2004	4.03	90912.5	30171	0
75%	2011	4.18	119736	971885	1
max	2024	4.77	11024224	1900000000000	1
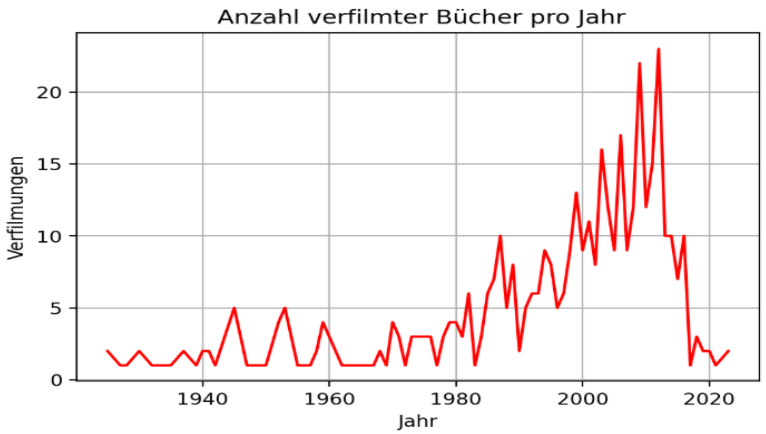
Visualisierung